Министерство науки и высшего образования Российской Федерации Федеральное государственное автономное образовательное учреждение высшего образования

«Уральский федеральный университет имени первого Президента России Б.Н. Ельцина» г. Екатеринбург

ОТЧЁТ

по лабораторной работе №4.

по дисциплине «Методы и инструменты анализа больших данных»

Ф.И.О.: Фадхил Фадхил Аббас Фадхил && Хасан Мухаммед Али
Институт: Институт радиоэлектроники и информационных технологий-РТФ

Группа: РИМ-201211

Направление: 10.04.01

Направленность: Информационная безопасность

Преподаватель			С.Г. Мирвода
	(дата)	(подпись)	
Студент			Ф. Ф. Аббас
	(дата)	(подпись)	
Студент			Х. М. Али
	(дата)	(подпись)	

Екатеринбург 2021

Table of Contents

Задание 0	3
Установить на свой кластер hadoop 3.3 СУБД HIVE 3.1.2 согласно инструкции и примеру	3
Войти под пользователем hive и запустить консольную утилиту hive	3
Выполнить команду select version();	4
Задание 1	4
Воспроизведите примеры из лекции и сохраните скрипт в свой репозиторий	4
Задание 2	4
Загрузите тестовый массив данных в текущую папку (файл большой и в облаке, может качат долго)	
С помощью команд head и wc -l изучите его содержимо	5
Создайте тестовую таблицу при помощи кода в примере 1 и загрузите в неё данные записав отчёт скорость записи каждого файла (для каждого следующего файла таблицу можно удаля или создавать новую с другим именем), количество строк и скорость выполнения запроса count(*).	ять
Задание 3	6
Дополнив оставшимися колонками пример ниже загрузите данные в таблицы HIVE, замеры время загрузки и запишите в отчёт	
В итоговой таблице должно содержаться 16 колонок и 26_541_204 строк	7
6.1. Количество загруженных	7
6.2. Средняя цена за год	8
6.3 Средняя цена за год в Городе 6.4 Самые дорогие районы	9

Задание 0

Задача подготовить полигон

Установить на свой кластер hadoop 3.3 СУБД HIVE

3.1.2 согласно инструкции и примеру

sudo wget https://dlcdn.apache.org/hive/hive-3.1.2/apache-hive-3.1.2-bin.tar.gz

```
fadhil@ubuntu:-$ sudo wget https://dlcdn.apache.org/hive/hive-3.1.2/apache-hive-3.1.2-bin.tar.gz [sudo] password for fadhil:
--2021-12-27 03:35:33-- https://dlcdn.apache.org/hive/hive-3.1.2/apache-hive-3.1.2-bin.tar.gz [sudo] password for fadhil:
--2021-12-27 03:35:33-- https://dlcdn.apache.org/hive/hive-3.1.2/apache-hive-3.1.2-bin.tar.gz [sudo] dlcdn.apache.org (dlcdn.apache.org)... 151.101.2.132, 2a04:4e42::644 [sudo] connecting to dlcdn.apache.org (dlcdn.apache.org)] [sudo] [su
        apache-hive-3.1.2-bin.tar.gz
                                                                                                                                                                                                                                                                                                                                    100%[===========
    2021-12-27 03:43:44 (556 KB/s) - 'apache-hive-3.1.2-bin.tar.gz' saved [278813748/278813748]
```

tar -xzvf apache-hive-3.1.2-bin.tar.gz

sudo mv apache-hive-3.1.2-bin /usr/local/

```
adhil@ubuntu:~$ sudo mv apache-hive-3.1.2-bin /usr/local/
drwxr-xr-x 14 root root 4096 Dec 27 03:49
drwxr-xr-x 14 root root 4096 Aug 19 03:32
drwxrwxr-x 10 fadhil fadhil 4096 Dec 27 03:44
drwxr-xr-x 2 root root 4096 Aug 19 03:29
drwxr-xr-x 2 root root 4096 Aug 19 03:29
```

/ .bashrc

```
export HADOOP_HOME=/usr/local/hadoop
                                 ME/bin:PATH=$HADOO
export PATH=$PATH:$HADOO
export HADOOP_CLASSPATH=
                                                            /sbin
                                         /libs/tools.jar
export HIEV_HOME=/usr/local/apache-hive-3.1.2-bin
export CLASSPATH
                                            /lib:
                                                               /share/hadoop/common/lib
                                 /bin
```

Войти под пользователем hive и запустить консольную утилиту hive

```
Bubuntu:/home/fadhil# hiveserver2
-12-27 04:25:51: Starting HiveServer2
: Class path contains multiple SLF4J bindings.
]: Found binding in [jar:ftle:/usr/local/apache-hive-3.1.2-bin/lib/log4j-slf4j-impl-2.10.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
]: Found binding in [jar:ftle:/usr/local/hadoop-3.3.1/share/hadoop/common/lib/slf4j-log4j12-1.7.30.jar!/org/slf4j/impl/StaticLoggerBinde
     See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
Actual binding is of type [org.apache.logging.slf4j.log4jLoggerFactory]
ission ID = f5df0759-5bc7-4804-812d-bf9c6688fd62
ission ID = Zee7c1bb-00fc-4406-8823-649515b0d892
           u:/nome/raontu# nive
ss path contains multiple SLF4J bindings.
nd binding in [jar:file:/usr/local/apache-hive-3.1.2-bin/lib/log4j-slf4j-impl-2.10.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
nd binding in [jar:file:/usr/local/hadoop-3.3.1/share/hadoop/common/lib/slf4j-log4j12-1.7.30.jar!/org/slf4j/impl/StaticLoggerBinde
ng initialized using configuration in jar:file:/usr/local/apache-hive-3.1.2-bin/lib/hive-common-3.1.2.jar!/hive-log4j2.properties Async:
       MR is deprecated in Hive 2 and may not be available in the future versions. Consider using a different execution engine (i.e. spark,
```

Выполнить команду select version();

```
class]
SLF41: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF41: Actual binding is of type [org.apache.logging.slf4j.log4jloggerFactory]
Hive Session ID = 70fdeb23-b2e4-4c74-85a9-29b922e0db3b
Logging initialized using configuration in jar:file:/usr/local/apache-hive-3.1.2-bin/lib
true
Hive-on-MR is deprecated in Hive 2 and may not be available in the future versions. Cons
ez) or using Hive 1.X releases.
Hive Session ID = 8ebf25f6-274e-4f49-9c9c-8ca9126e5db6
hive-select version();
OK
3.1.2 r8190d2be7b7165effa62bd21b7d60ef81fb0e4af
Time taken: 4.325 seconds, Fetched: 1 row(s)
hive-
```

Задание 1

Воспроизведите примеры из лекции и сохраните скрипт в свой репозиторий

```
hive> create table pokes(foo int, bar string);
OK
Time taken: 1.083 seconds
hive> create table invites(foo int, bar string) partitioned by (ds string);
OK
Time taken: 0.146 seconds
hive> show tables
> ;
OK
invites
pokes
Time taken: 0.183 seconds, Fetched: 2 row(s)
hive>
hive> describe invites;
OK
foo int
bar string
ds string

# Partition Information
# col_name data_type comment
ds string
Time taken: 0.425 seconds, Fetched: 7 row(s)
hive>
hive> ALTER TABLE invites ADD COLUMNS(col2 int comment 'my new col');
OK
Kine taken: 0.315 seconds
hive> describe invites;
OK
Time taken: 0.315 seconds
hive> describe invites;
OK
Time taken: 0.325 seconds, Fetched: 8 row(s)
hive> drop table pokes

> ;
OK
Time taken: 0.731 seconds
hive drop table pokes
> ;
OK
Time taken: 0.731 seconds
```

Задание 2

Загрузите тестовый массив данных в текущую папку (файл большой и в облаке, может качаться долго).

С помощью команд head и wc -1 изучите его содержимо

```
Fight 18 (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19 ) (19
```

cat pp-complete.csv | head -100000 > pp-100k.csv cat pp-100k.csv | wc -l

hive>

Создайте тестовую таблицу при помощи кода в примере 1 и загрузите в неё данные записав в отчёт скорость записи каждого файла (для каждого следующего файла таблицу можно удалять или создавать новую с другим именем), количество строк и скорость выполнения запроса count(*).

CREATE TABLE price test (id int, price string, dt string) row format delimited fields terminated by ",";

```
hive> CREATE TABLE price_test (id int , price string, dt string) row format delimited fields terminated by ",";
OK
Time taken: 2.989 seconds

Load data Local INPATH 'pp-100k.csv' overwrite into table price_test;
hive> Load data Local INPATH 'pp-100k.csv' overwrite into table price_test;
Loading data to table default.price_test
OK
Time taken: 2.772 seconds
```

sudo cp pp-100k.csv /usr/local/

```
hive> SELECT * from price_test; Time taken: 0.265 seconds, Fetched: 100000 row(s)
```

1m

CREATE TABLE price_test_1m (id int , price string, dt string) row format delimited fields terminated by ".":

```
hive> CREATE TABLE price_test_1m (id int , price string, dt string) row format delimited fields terminated by ",";
OK
Time taken: 1.596 seconds
```

Load data Local INPATH 'pp-1m.csv' overwrite into table price_test_1m;

```
hive> Load data Local INPATH 'pp-1m.csv' overwrite into table price_test_1m;
Loading data to table default.price_test_1m
OK
Time taken: 3.37 seconds
```

```
hive> SELECT * from price_test_1m;
```

```
Time taken: 5.602 seconds, Fetched: 1000000 row(s)
```

10m

CREATE TABLE price_test_10m (id int , price string, dt string) row format delimited fields terminated by ",";

Load data Local INPATH 'pp-10m.csv' overwrite into table price_test_10m;

```
hive> Load data Local INPATH 'pp-10m.csv' overwrite into table price_test_10m; Loading data to table default.price_test_10m
OK
Time taken: 34.282 seconds
hive>
```

```
hive> select * from price_test_10m;

Time taken: 0.207 seconds, Fetched: 10000000 row(s)
hive>
```

Залание 3

Дополнив оставшимися колонками пример ниже загрузите данные в таблицы HIVE, замерьте время загрузки и запишите в отчёт

```
CREATE TABLE price (
id STRING,
price INT,
datetime DATE,
postcode STRING,
```

```
property type STRING,
  new_build_flag STRING,
  tenure type STRING,
  primary addressable object name STRING,
  secondary_addressable_object_name STRING,
  street STRING,
  locality STRING,
  town_city STRING,
  district STRING,
  county STRING
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES ("separatorChar" = ",", "quoteChar"="\"", "escapeChar"="\\")
STORED AS TEXTFILE;
  Time taken: 1.186 seconds
 ive> describe price2;
    e_type string
ry_addressable_object_name string
dary_addressable_object_name
    string
maken: 2.195 seconds, Fetched: 14 row(s)
```

LOAD DATA LOCAL INPATH 'opt/pp-complete.csv' OVERWRITE INTO TABLE price; select * from price2 limit 10;

```
New Select " from price2 linkt 19; (**

(***GESTRES-7035-4415-3868-72562(210958)**, '76000***, '1995-07-78 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**, '1915-07-77 00:90**
```

В итоговой таблице должно содержаться 16 колонок и 26 541 204 строк.

```
Ended Job = job_1640286116539_0008
MapReduce Jobs Launched:
Stage-Stage-1: Map: 18 Reduce: 1 Cumulative CPU: 299.4 sec
Total MapReduce CPU Time Spent: 4 minutes 59 seconds 400 msec
OK
26541204
Time taken: 161.226 seconds, Fetched: 1 row(s)
```

6.1. Количество загруженных строк данных

"select date_format(datetime, 'yyyy'),town_city,cast(avg(price) as INT) from price group by date format(datetime, 'yyyy').town_city:" > f1.txt

```
group by date_format(datetime, 'yyyyy'),town_city;" > f1.txt
MapReduce Total cumulative CPU time: 33 minutes 8 seconds 710 msec
Ended Job = job_1640294990941_0001
MapReduce Jobs Launched:
Stage-Stage-1: Map: 18 Reduce: 19 Cumulative CPU: 1988.71 sec HDFS Read: 4641648970 HDFS Write: 2296 SUCCESS
Total MapReduce CPU Time Spent: 33 minutes 8 seconds 710 msec
OK
Time taken: 261.199 seconds, Fetched: 27 row(s)
```

```
27 lines (27 sloc) 319 Bytes
            71506
            78532
     1998
            85436
     1999
            96037
      2000
             107483
      2001
            118885
      2002
             137942
             155888
             203528
             219378
     2007
     2008
             217056
             213419
     2009
     2010
             236109
     2011
             232804
             238366
             256923
      2014
            279938
             297266
             313222
             351488
```

6.2. Средняя цена за год

Hive "select date_format(datetime, 'yyyy'),town_city,cast(avg(price) as INT) from price group by date_format(datetime, 'yyyy'),town_city order by date_format(datetime, 'yyyy');" > f2.txt

```
Executable File | 31180 lines (31180 sloc) | 670 KB
      1995 WELLINGBOROUGH 45870
            WEYBRIDGE
                          157201
     1995 AMLWCH 37322
            ASHBOURNE
                          86230
      1995
            ASHFORD 74976
            PRENTON 53984
            PENARTH 74589
            BACUP 32905
            BARNSLEY
            BATTLE 91825
            BEAMINSTER
            BEWDLEY 72812
            BINGLEY 63478
            BOGNOR REGIS 66521
            BORFHAMWOOD
                          85596
            BOURNE 57090
            BUCKHURST HILL 106542
     1995 CALLINGTON
                          58493
     1995 CARNFORTH
```

```
MapReduce Total cumulative CPU time: 12 seconds 490 msec
Ended Job = job_1640294990941_0005
MapReduce Jobs Launched:
Stage-Stage-1: Map: 18 Reduce: 19 Cumulative CPU: 1901.96 sec HDFS Read: 4641643163 HDFS Write: 1128126 SUCCESS
Stage-Stage-2: Map: 3 Reduce: 1 Cumulative CPU: 12.49 sec HDFS Read: 1147174 HDFS Write: 1060693 SUCCESS
Total MapReduce CPU Time Spent: 31 minutes 54 seconds 450 msec
OK
Time taken: 250.612 seconds, Fetched: 31180 row(s)
```

6.3 Средняя цена за год в Городе 6.4 Самые дорогие районы

Hive "select district, cast(avg(price) as INT) from price group by district order by cast(avg(price) as INT) DESC;" > f3.txt

```
MapReduce Total cumulative CPU time: 10 seconds 100 msec
Ended Job = job_1640249999941_0011

MapReduce Jobs Launched:

Stage-Stage-1: Map: 18 Reduce: 19    Cumulative CPU: 332.3 sec    HDFS Read: 4641638708 HDFS Write: 17074 SUCCESS

Stage-Stage-2: Map: 3   Reduce: 1   Cumulative CPU: 10.1 sec    HDFS Read: 35532 HDFS Write: 14384 SUCCESS

Total MapReduce CPU Time Spent: 5 minutes 42 seconds 400 msec

OK    Time taken: 66.052 seconds. Entched: 463 cms(s)
```